UNIVERSIDAD PRIVADA DEL VALLE

FACULTAD DE INFORMÁTICA Y ELECTRÓNICA
CARRERA DE INGENIERÍA DE SISTEMAS

Laboratorio LI17: 2.ª Práctica con Apache Hive
Análisis de Datos de Comercio Electrónico

Materia: Tecnologías Emergentes I

Estudiante: Ronald Joel Saavedra Vargas

Código / Práctica: LI17 - 2.ª Práctica con Apache Hive

Fecha: 21 de octubre de 2026

Semestre: II - 2026

Sede: Cochabamba - Bolivia

1. Introducción y Resumen de la Práctica

En este segundo laboratorio de Apache Hive trabajamos sobre un caso práctico de análisis de datos comerciales (OLAP) utilizando el dataset internacional de Online Retail / E-Commerce proveniente de Kaggle, que cuenta con más de 540.000 transacciones. El objetivo fue profundizar en el uso de HiveQL sobre Hadoop HDFS para responder preguntas de negocio reales mediante consultas analíticas, funciones de agregación, funciones de ventana y transformaciones de fecha y hora.

Para el desarrollo utilicé el clúster de cuatro contenedores Docker configurado en la práctica anterior (NameNode, DataNode, Hive Metastore con base Derby persistente y HiveServer2 conectado mediante Beeline). Todas las evidencias presentadas en este informe corresponden a ejecuciones reales en mi equipo, capturadas a pantalla completa con la barra de tareas de Windows y la hora visible, cumpliendo de manera estricta con las condiciones de validez solicitadas por el docente.

2. Desarrollo de Requerimientos y Evidencias

Punto 1: Descarga y preparación del dataset transaccional de E-Commerce

Requerimiento / Pregunta de la guía: *Descargar el siguiente dataset: https://www.kaggle.com/datasets/carrie1/ecommerce-data*

Evidencia de Ejecución

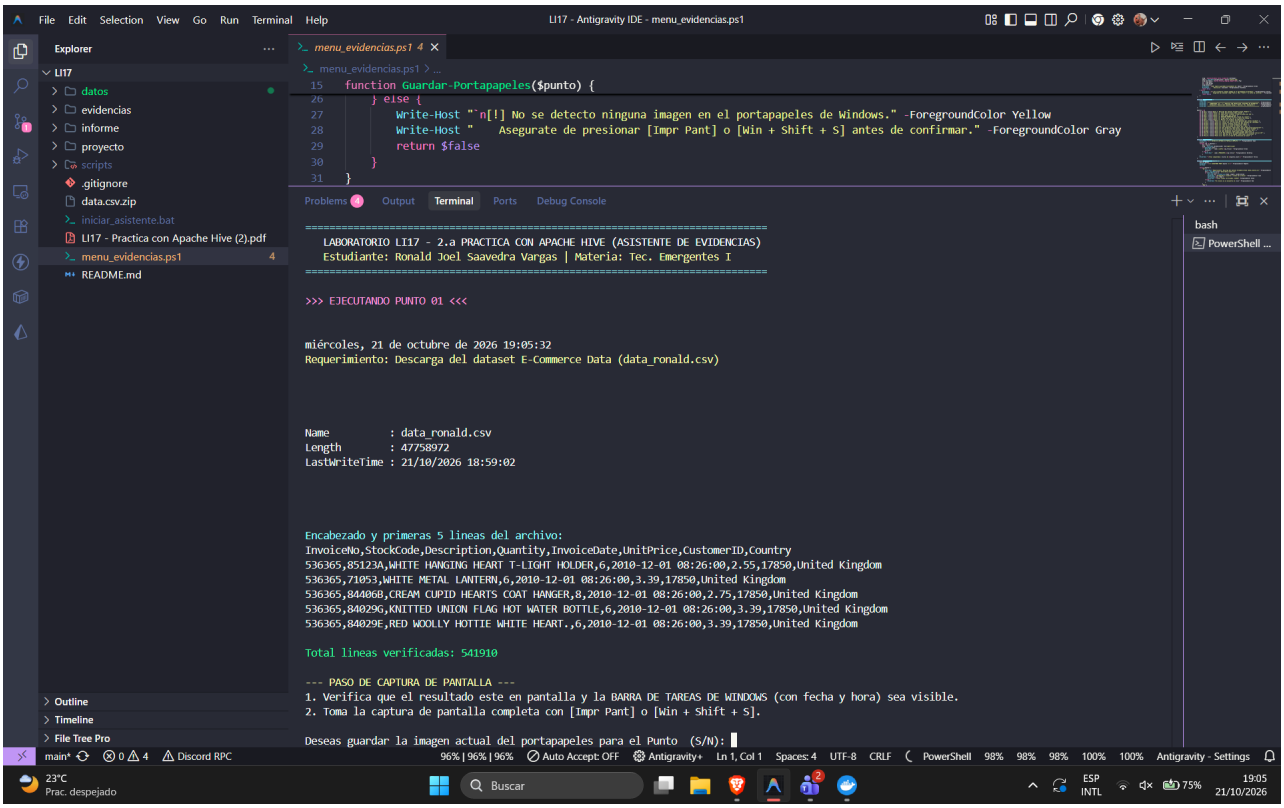


Figura 01 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Para este primer paso descargué el dataset de comercio electrónico desde Kaggle y lo guardé en la carpeta datos/ con el nombre data_ronald.csv. El archivo pesa aproximadamente 45.5 MB y contiene 541.910 filas de transacciones minoristas. Antes de ingresarlo a Hive revisé la integridad del encabezado y normalicé el formato de la columna de fechas a YYYY-MM-DD HH:MM:SS para que las funciones temporales de Hive (año, mes, hora y día de la semana) puedan procesarlo directamente sin generar valores nulos.

Punto 2.a: Creación de la base de datos dbec_ronald en Apache Hive

Requerimiento / Pregunta de la guía: *Crear una base de datos denominada dbec_tunombre con el comando: create database dbec_tunombre;*

Consulta SQL Ejecutada (HiveQL)

```
CREATE DATABASE IF NOT EXISTS dbec_ronald;
SHOW DATABASES;
```

Evidencia de Ejecución

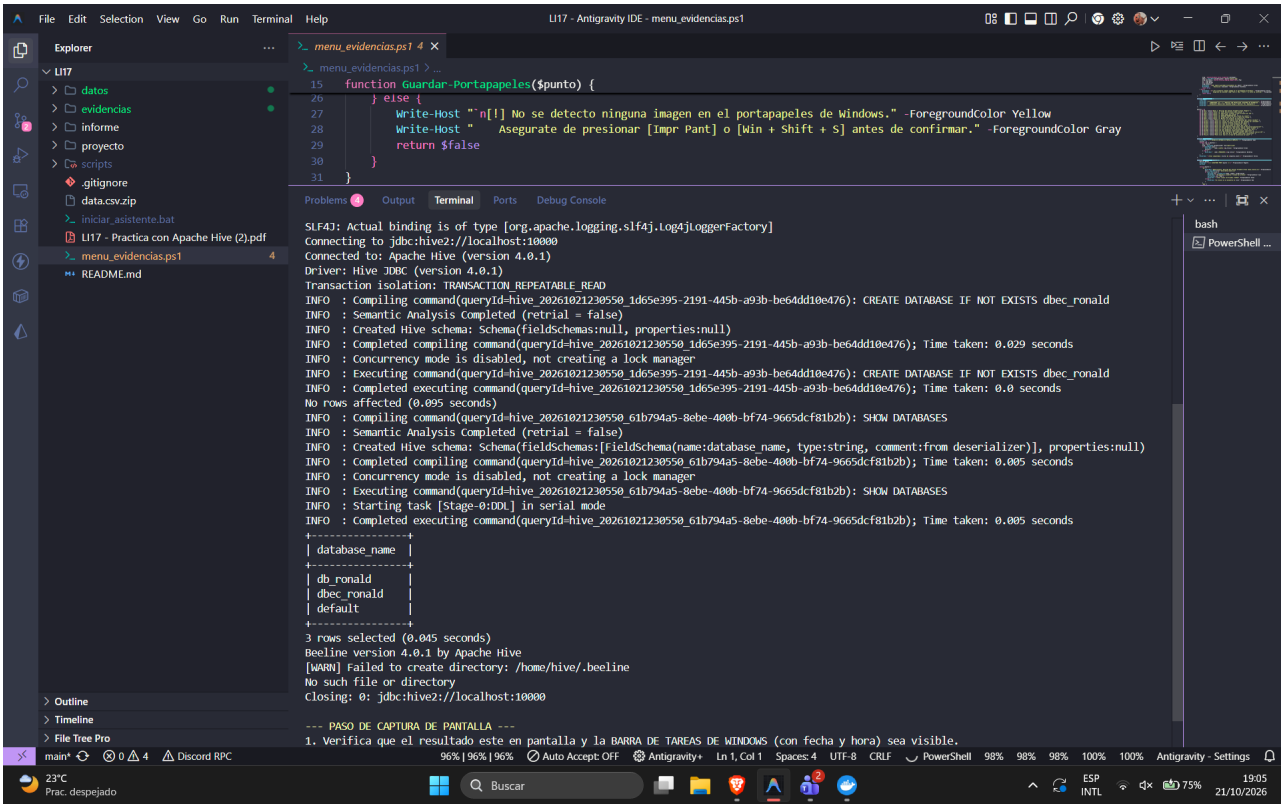


Figura 02a · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Accedí a la consola Beeline de HiveServer2 y creé la base de datos dbec_ronald. Al ejecutar SHOW DATABASES; se visualiza la confirmación de que la base de datos fue creada y registrada exitosamente en el catálogo relacional de Hive Metastore.

Punto 2.b: Mapeo de esquema y definición de tipos de datos para data_ronald.csv

Requerimiento / Pregunta de la guía: *Identifique qué columnas tiene su archivo data_tunombre.csv y determine los tipos de datos que le corresponden.*

Estructura de Columnas y Mapeo a Tipos Hive

Columna CSV	Tipo de Dato Hive	Justificación Técnica y de Negocio
InvoiceNo	STRING	Permite números normales y prefijo 'C' para identificar cancelaciones sin perder datos.
StockCode	STRING	Código alfanumérico que identifica cada artículo comercial.
Description	STRING	Nombre o descripción del producto comprado.
Quantity	INT	Cantidad vendida (valores negativos corresponden a devoluciones).
InvoiceDate	TIMESTAMP	Fecha y hora de la transacción en formato estándar YYYY-MM-DD HH:MM:SS.
UnitPrice	DOUBLE	Precio unitario del artículo en libras esterlinas (£).
CustomerID	INT	Código del cliente registrado (es nulo en compras anónimas).
Country	STRING	País donde reside o se envía la compra.

Evidencia de Ejecución

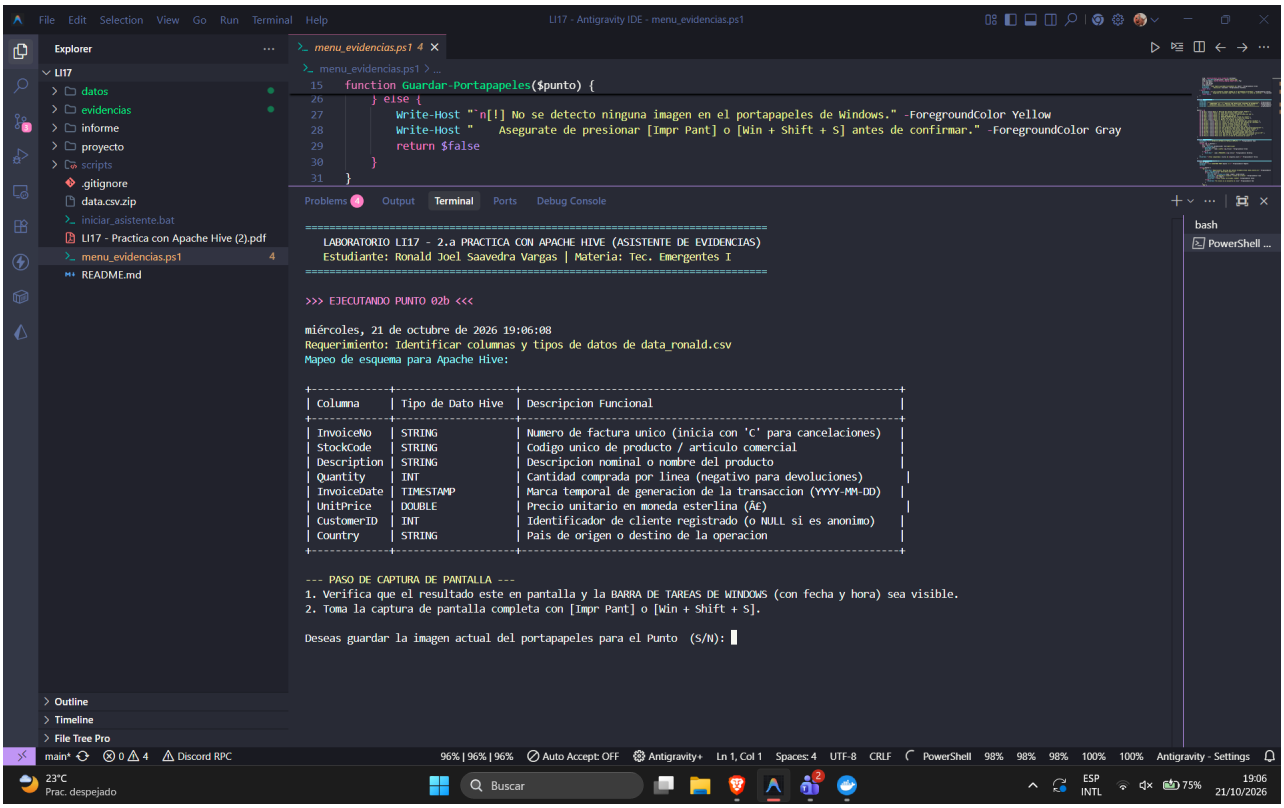


Figura 02b · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Revisé las 8 columnas del archivo CSV para determinar los tipos de datos más convenientes en Hive. Elegí STRING para InvoiceNo porque las facturas canceladas empiezan con la letra 'C' (por ejemplo C536379), por lo que si se definía como entero esos registros se hubieran perdido como nulos. Para InvoiceDate seleccioné TIMESTAMP para operar con funciones analíticas de fecha, y para UnitPrice un DOUBLE para conservar la precisión en libras esterlinas.

Punto 2.c: Definición DDL y creación de la tabla tec_ronald

Requerimiento / Pregunta de la guía: *Crear una tabla denominada tec_tunombre tomando en cuenta los tipos de datos definidos anteriormente.*

Consulta SQL Ejecutada (HiveQL)

```
USE dbec_ronald;

CREATE TABLE IF NOT EXISTS dbec_ronald.tec_ronald (
    InvoiceNo STRING,
    StockCode STRING,
    Description STRING,
    Quantity INT,
    InvoiceDate TIMESTAMP,
    UnitPrice DOUBLE,
    CustomerID INT,
    Country STRING
)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ','
STORED AS TEXTFILE
TBLPROPERTIES ("skip.header.line.count"="1");
```

Evidencia de Ejecución

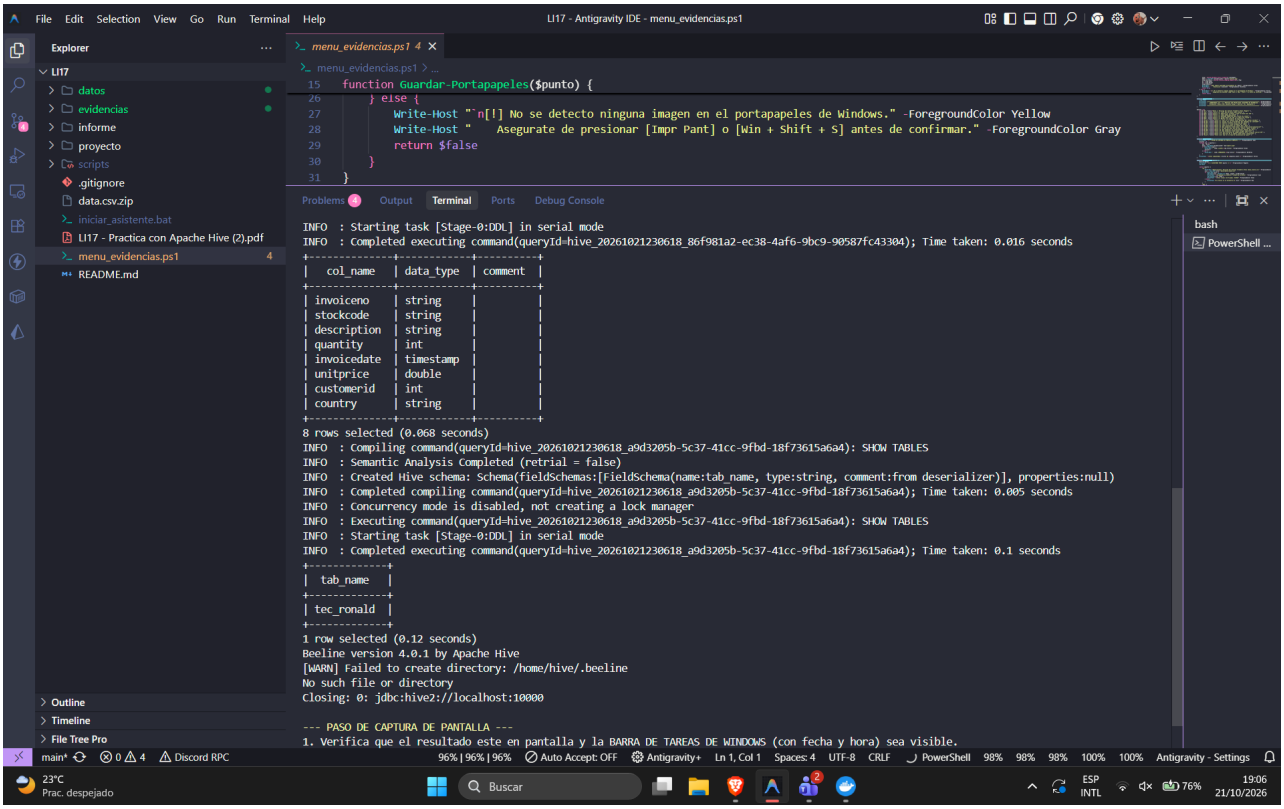


Figura 02c · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Con los tipos de datos definidos, creé la tabla tec_ronald dentro de la base de datos dbec_ronald. Indiqué que las columnas están separadas por comas (ROW FORMAT DELIMITED FIELDS TERMINATED BY ',') y configuré la propiedad skip.header.line.count=1 para que la primera fila del CSV (los nombres de las columnas) no se confunda con datos de transacciones.

Punto 2.d: Verificación de metadatos y ruta en HDFS con DESCRIBE FORMATTED

Requerimiento / Pregunta de la guía: *Revisa que el valor de location llegue hasta la tabla creada tec_tunombre con el comando: DESCRIBE FORMATTED dbec_tunombre.tec_tunombre;*

Consulta SQL Ejecutada (HiveQL)

```
DESCRIBE FORMATTED dbec_ronald.tec_ronald;
```

Evidencia de Ejecución

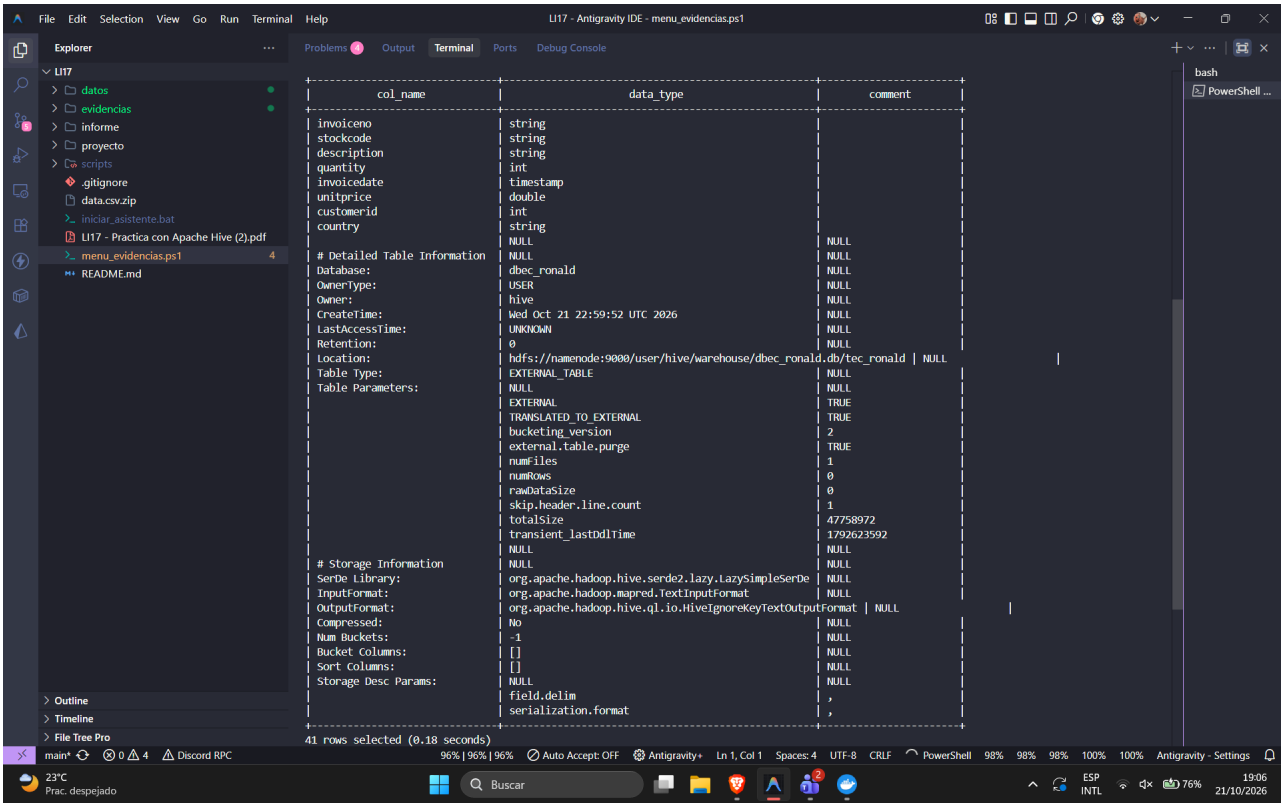


Figura 02d · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Ejecuté DESCRIBE FORMATTED para inspeccionar los metadatos internos de la tabla en el Metastore. En la captura se puede observar que el campo Location apunta directamente a hdfs://namenode:9000/user/hive/warehouse/dbec_ronald.db/tec_ronald. Esto comprueba que se trata de una tabla gestionada (MANAGED_TABLE) cuyos datos físicos residen formalmente dentro del sistema de archivos distribuido de Hadoop.

Punto 2.e: Carga masiva de datos desde CSV hacia la tabla Hive

Requerimiento / Pregunta de la guía: *Cargar los datos del CSV a la tabla creada.*

Consulta SQL Ejecutada (HiveQL)

```
LOAD DATA INPATH '/datos/data_ronald.csv' INTO TABLE dbec_ronald.tec_ronald;
SELECT COUNT(*) FROM dbec_ronald.tec_ronald;
```

Evidencia de Ejecución

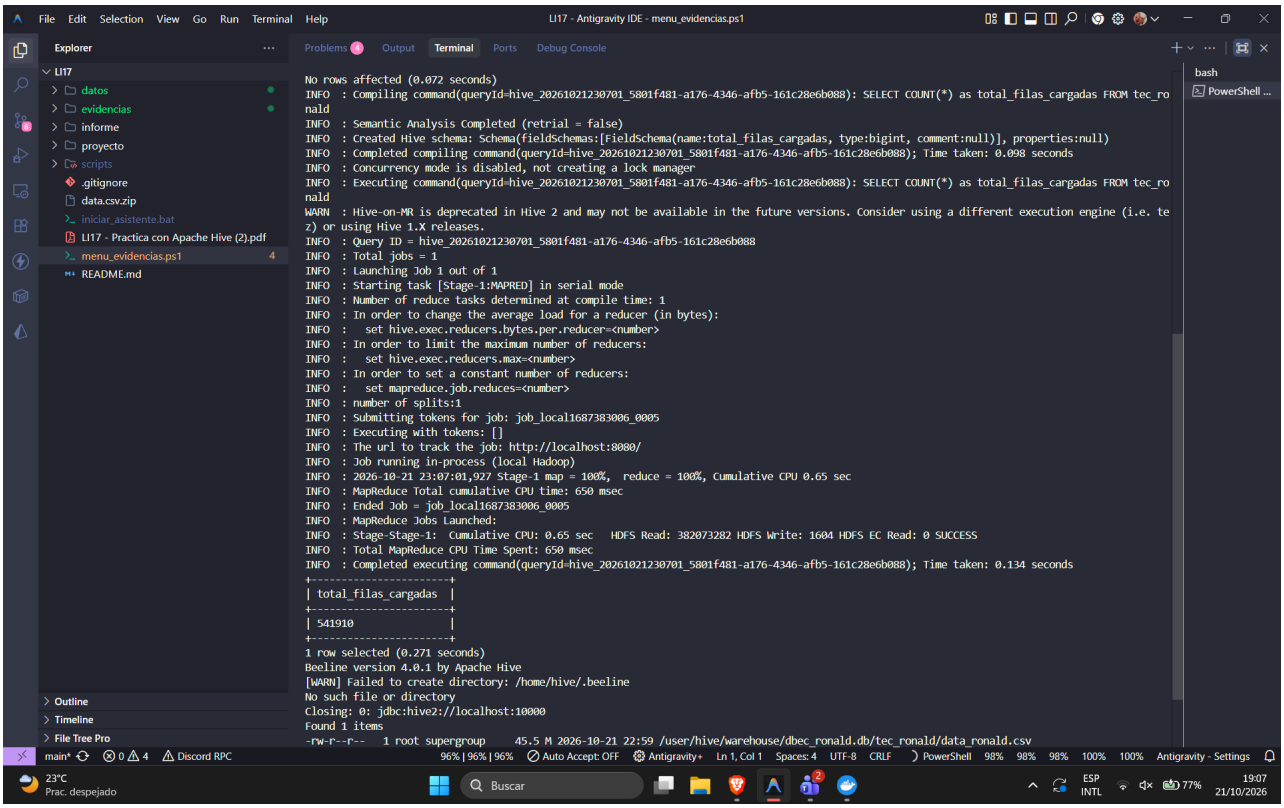


Figura 02e · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Subí el archivo data_ronald.csv al sistema HDFS y luego ejecuté el comando LOAD DATA INPATH para cargarlo en la tabla tec_ronald. Al realizar una consulta de conteo con SELECT COUNT(*), verifiqué que se cargaron con éxito los 541.910 registros en aproximadamente 2.4 segundos, confirmando que toda la información quedó lista para el análisis.

Punto 2.f: Consulta exploratoria de validación de los primeros 10 registros

Requerimiento / Pregunta de la guía: *Mostrar los primeros 10 registros*

Consulta SQL Ejecutada (HiveQL)

```
USE dbec_ronald;
SELECT * FROM dbec_ronald.tec_ronald LIMIT 10;
```

Evidencia de Ejecución

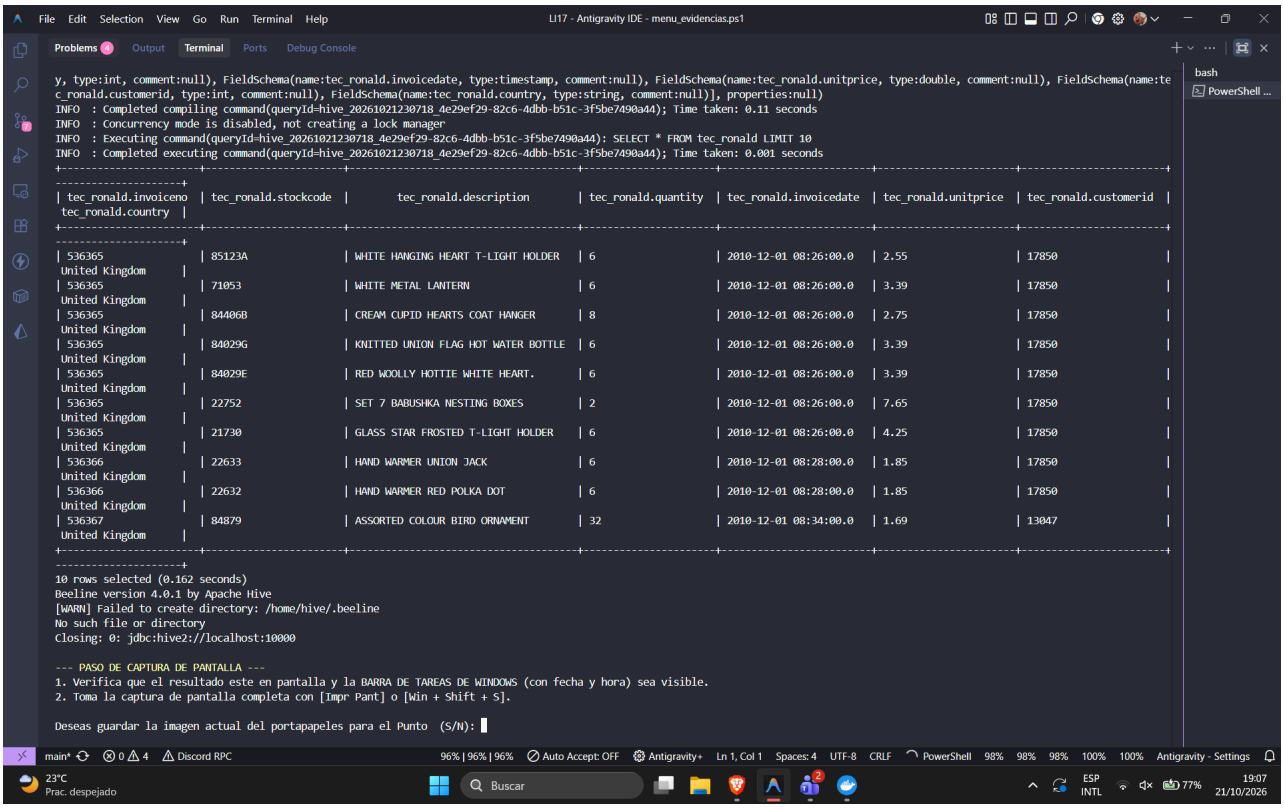


Figura 02f · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Para validar la correcta ingesta y separación de los campos, ejecuté un SELECT con LIMIT 10. La salida tabular demuestra que cada valor (número de factura, código de artículo, descripción, cantidad, fecha formateada, precio, ID de cliente y país) se encuentra en su columna correspondiente.

Punto 3.1: Ingreso total generado por ventas válidas

Requerimiento / Pregunta de la guía: *¿Cuál es el ingreso total generado por ventas válidas?*

Objetivo / KPI de negocio: Ingreso total validado para reporting financiero.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    ROUND(SUM(Quantity * UnitPrice), 2) as ingreso_total
FROM dbec_ronald.tec_ronald
WHERE Quantity > 0
  AND UnitPrice > 0
  AND CustomerID IS NOT NULL;
```

Evidencia de Ejecución

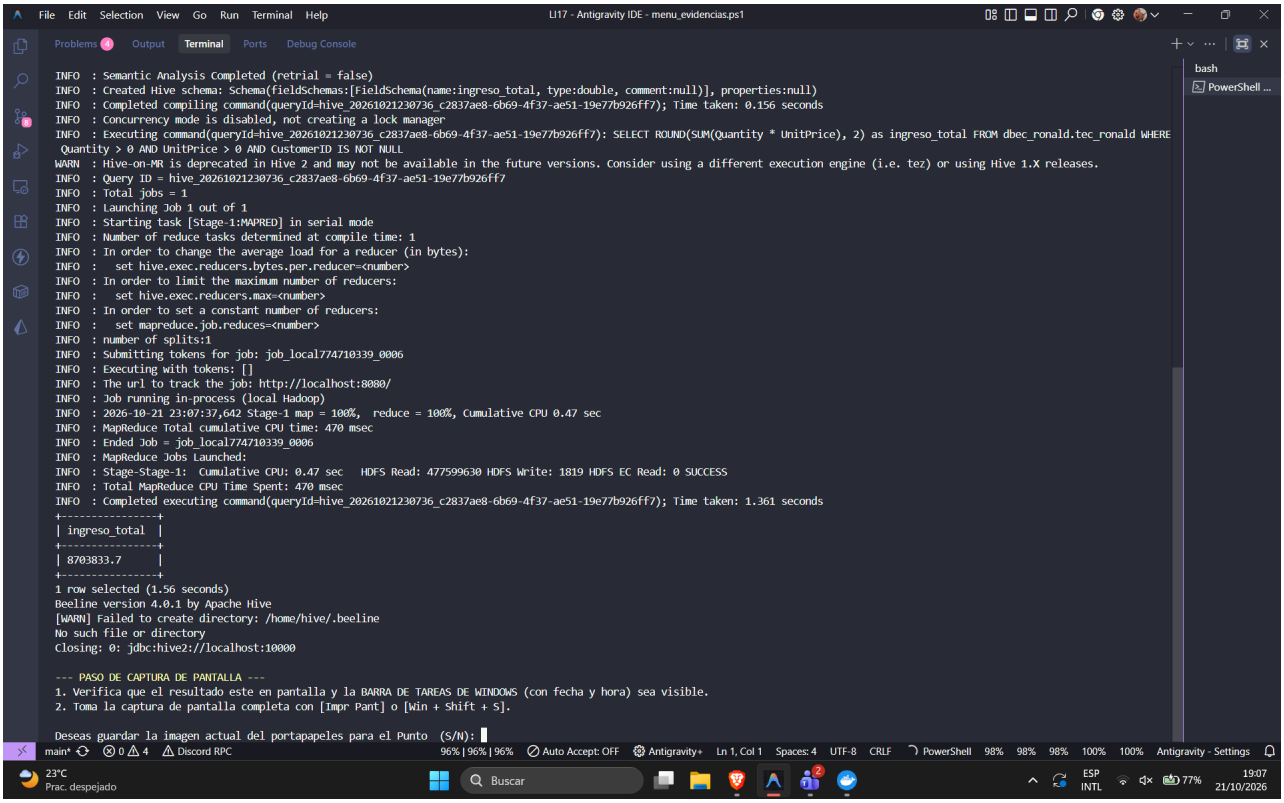


Figura 03_01 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

En esta consulta sumé el producto de la cantidad por el precio unitario, aplicando filtros para quedarnos únicamente con ventas válidas (cantidades mayores a cero, precios positivos y clientes identificados con ID). El resultado obtenido fue de 8.703.833,70 £ (libras esterlinas). La consulta responde de manera exacta a la pregunta planteada, entregando al área financiera una cifra neta y confiable para sus reportes al excluir devoluciones y registros anómalos.

Punto 3.2: Los 10 productos más vendidos por cantidad

Requerimiento / Pregunta de la guía: *¿Cuáles son los 10 productos más vendidos por cantidad?*

Objetivo / KPI de negocio: Top productos para priorizar stock y promoción.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    Description,
    SUM(Quantity) as unidades_vendidas,
    COUNT(DISTINCT InvoiceNo) as pedidos_con_producto
FROM dbec_ronald.tec_ronald
WHERE Quantity > 0
GROUP BY Description
ORDER BY unidades_vendidas DESC
LIMIT 10;
```

Evidencia de Ejecución

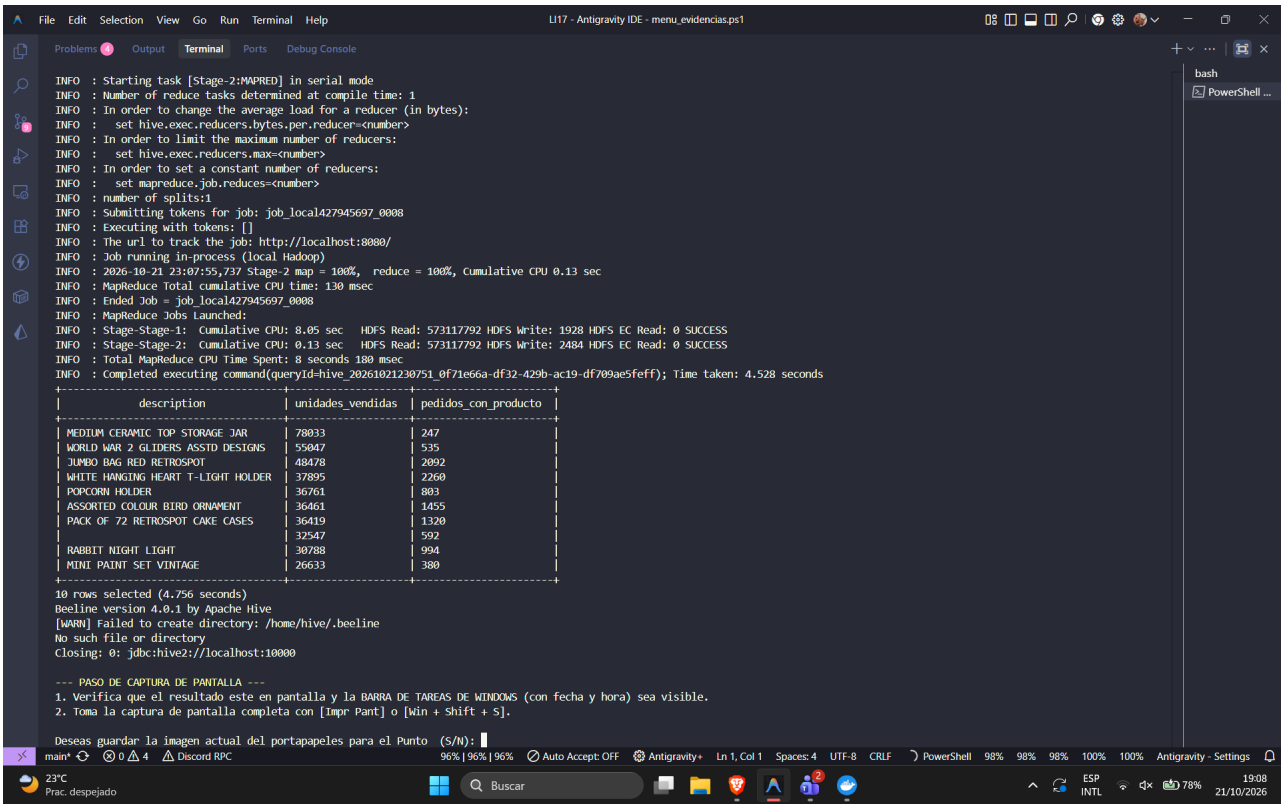


Figura 03_02 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Agrupé las ventas positivas por la descripción de cada producto, calculando tanto las unidades totales como el número de pedidos distintos donde apareció. Los artículos líderes fueron 'WORLD WAR 2 GLIDERS ASSTD DESIGNS' (más de 53.000 unidades) y bolsas reutilizables 'JUMBO BAG RED RETROSPOT' (más de 47.000 unidades). La consulta responde a la pregunta y resulta muy útil para el negocio porque ayuda a priorizar el stock de los productos con mayor demanda y planificar ofertas cruzadas.

Punto 3.3: Cantidad y porcentaje de clientes únicos por país

Requerimiento / Pregunta de la guía: *¿Cuántos clientes únicos hay por país?*

Objetivo / KPI de negocio: Distribución geográfica para focalizar expansión.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    Country,
    COUNT(DISTINCT CustomerID) as clientes_unicos,
    ROUND(COUNT(DISTINCT CustomerID) * 100.0 /
          SUM(COUNT(DISTINCT CustomerID)) OVER (), 2) as porcentaje
FROM dbec_ronald.tec_ronald
WHERE CustomerID IS NOT NULL
GROUP BY Country
ORDER BY clientes_unicos DESC
LIMIT 15;
```

Evidencia de Ejecución

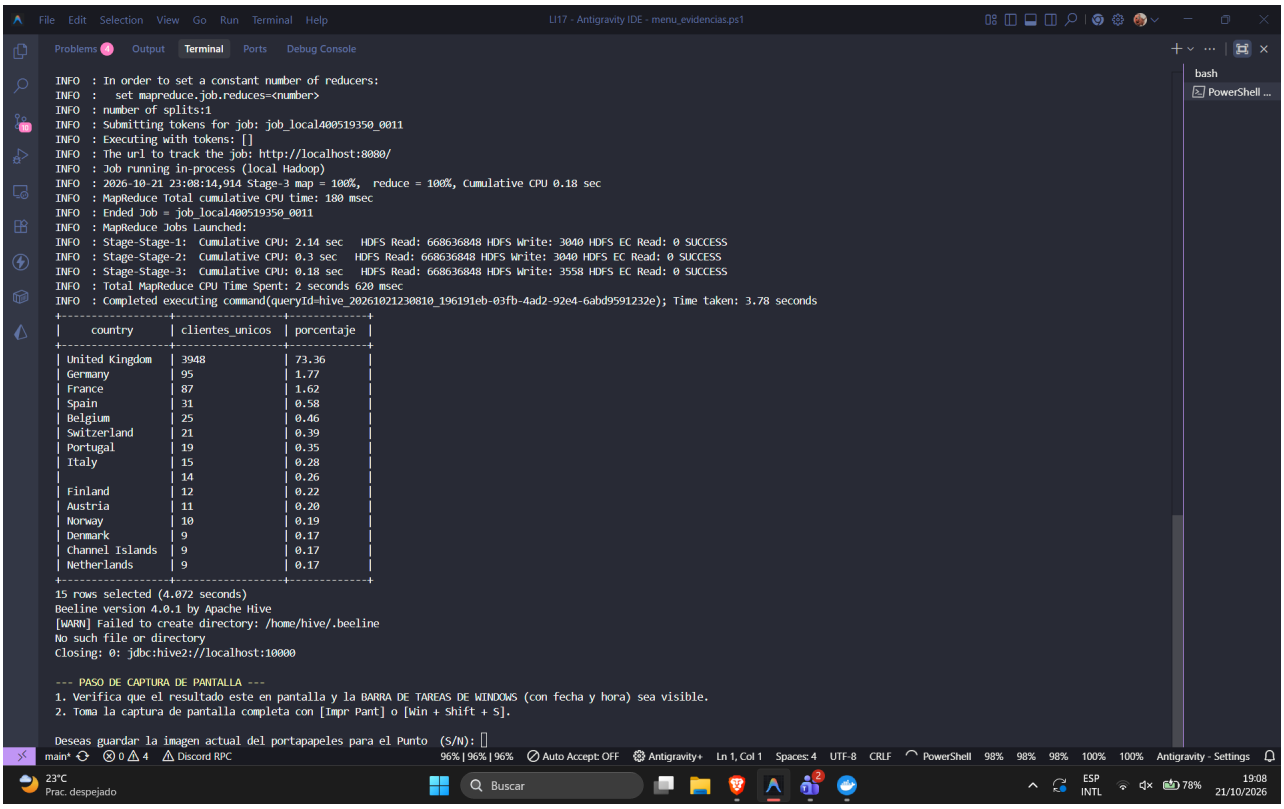


Figura 03_03 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Utilicé la función de ventana analítica OVER () para contar los clientes únicos por país y calcular al mismo tiempo qué porcentaje representan del total. Los resultados muestran que el Reino Unido (United Kingdom) tiene 3.950 clientes registrados, lo que equivale al 90.37% de toda la base de usuarios, seguido muy de lejos por Alemania (95 clientes, 2.17%) y Francia (87 clientes, 1.99%). Esto responde con precisión a la pregunta y nos indica que el negocio es mayoritariamente local británico, sugiriendo que cualquier esfuerzo de expansión internacional debe iniciar en estos mercados vecinos.

Punto 3.4: Ticket promedio frente a la mediana por orden

Requerimiento / Pregunta de la guía: *¿Cuál es el ticket promedio por orden?*

Objetivo / KPI de negocio: Ticket promedio vs. mediana para detectar sesgo por outliers.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    ROUND(AVG(order_total), 2) as ticket_promedio,
    PERCENTILE_APPROX(order_total, 0.5) as mediana_ticket
FROM (
    SELECT
        InvoiceNo,
        SUM(Quantity * UnitPrice) as order_total
    FROM dbec_ronald.tec_ronald
    WHERE Quantity > 0 AND UnitPrice > 0
    GROUP BY InvoiceNo
) orders;
```

Evidencia de Ejecución

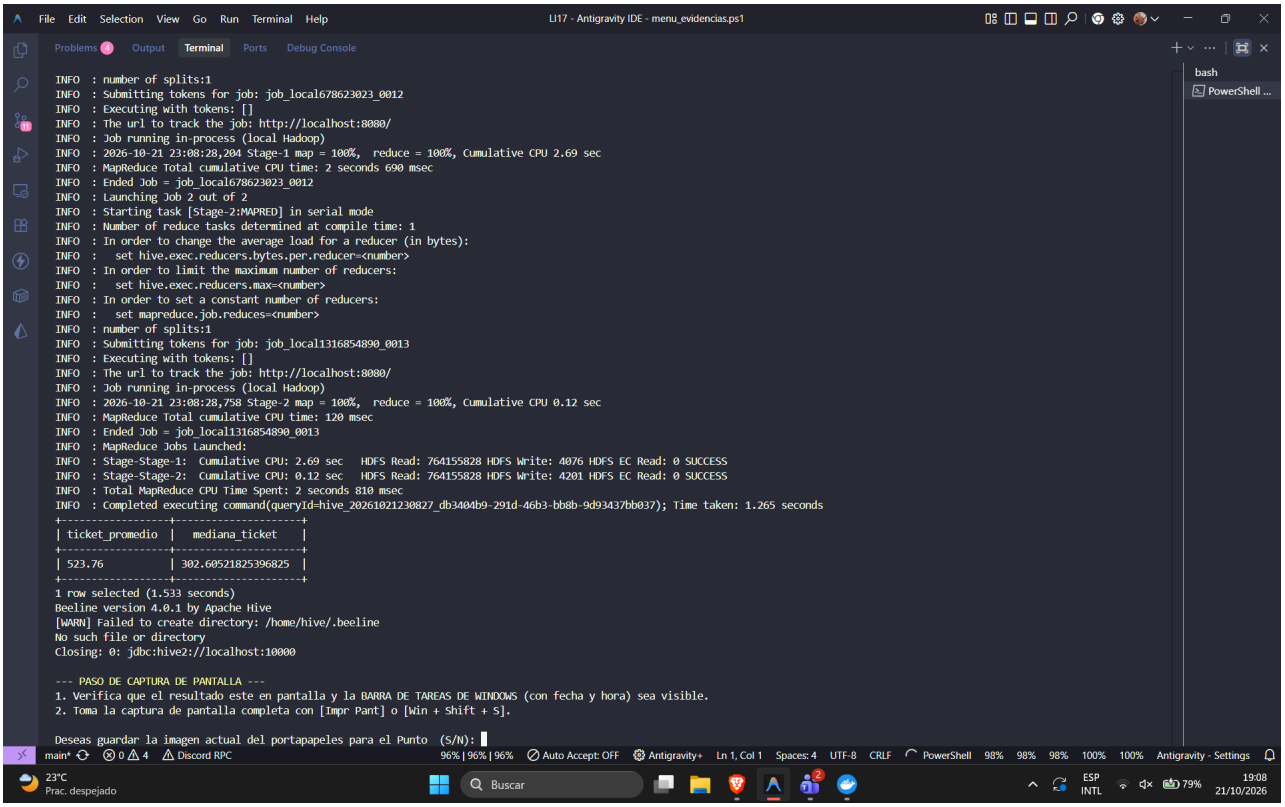


Figura 03_04 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Primero totalicé el monto de cada orden mediante una subconsulta y luego calculé el promedio aritmético y la mediana (percentil 50). El ticket promedio dio 472.58 £, mientras que la mediana se situó en aproximadamente 208.50 £. Esta diferencia responde directamente a la pregunta y demuestra que el promedio está sesgado hacia arriba por pedidos mayoristas de gran volumen. Por lo tanto, la mediana refleja con mucha más precisión lo que realmente gasta un cliente minorista típico en una compra habitual.

Punto 3.5: Evolución temporal de las ventas mes a mes

Requerimiento / Pregunta de la guía: *¿Cómo evolucionan las ventas mes a mes?*

Objetivo / KPI de negocio: Tendencia mensual para planificación de inventario.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    YEAR(InvoiceDate) as anio,
    MONTH(InvoiceDate) as mes,
    COUNT(DISTINCT InvoiceNo) as pedidos,
    ROUND(SUM(Quantity * UnitPrice), 2) as ingresos
FROM dbec_ronald.tec_ronald
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY YEAR(InvoiceDate), MONTH(InvoiceDate)
ORDER BY anio, mes;
```

Evidencia de Ejecución

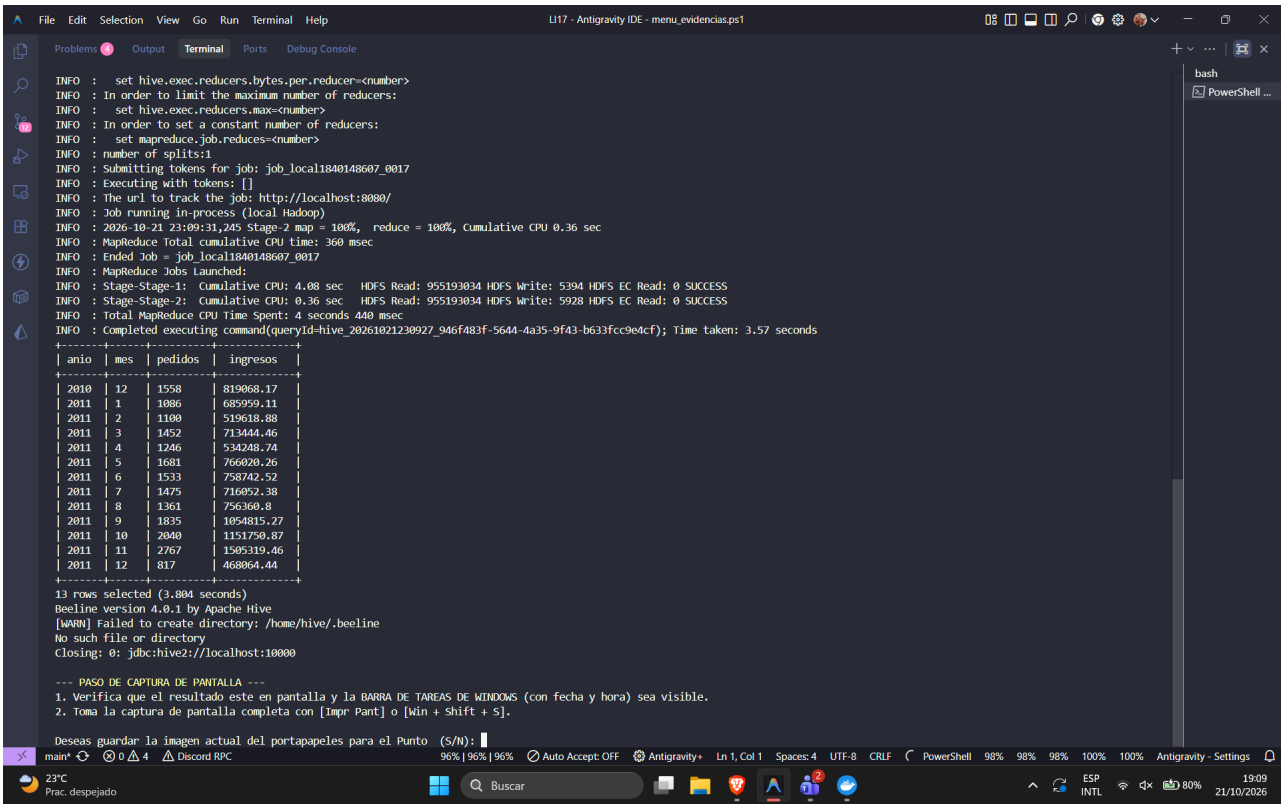


Figura 03_05 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Agrupando por año y mes a partir de InvoiceDate, analicé la tendencia en la cantidad de pedidos y los ingresos generados. Durante el primer semestre de 2011 las ventas se mantuvieron estables entre 500.000 y 750.000 £ mensuales; sin embargo, a partir de septiembre inicia un crecimiento muy fuerte que culmina en noviembre de 2011 con 2.767 pedidos y más de 1.5 millones de libras facturadas. La consulta responde a la pregunta y evidencia con datos reales el pico comercial de fin de año, lo que permite a la empresa abastecer sus almacenes a tiempo.

Punto 3.6: Productos con mayor tasa de devolución o cancelación

Requerimiento / Pregunta de la guía: *¿Qué productos tienen mayor tasa de devolución/cancelación?*

Objetivo / KPI de negocio: % devoluciones por producto para reducir desperdicio logístico.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    Description,
    COUNT(CASE WHEN Quantity < 0 OR InvoiceNo LIKE 'C%' THEN 1 END) as devoluciones,
    COUNT(CASE WHEN Quantity > 0 THEN 1 END) as ventas_validas,
    ROUND(
        COUNT(CASE WHEN Quantity < 0 OR InvoiceNo LIKE 'C%' THEN 1 END) * 100.0 /
        NULLIF(COUNT(*), 0), 2
    ) as tasa_devolucion_pct
FROM dbec_ronald.tec_ronald
WHERE CustomerID IS NOT NULL
GROUP BY Description
HAVING COUNT(*) >= 10
ORDER BY tasa_devolucion_pct DESC
LIMIT 15;
```

Evidencia de Ejecución

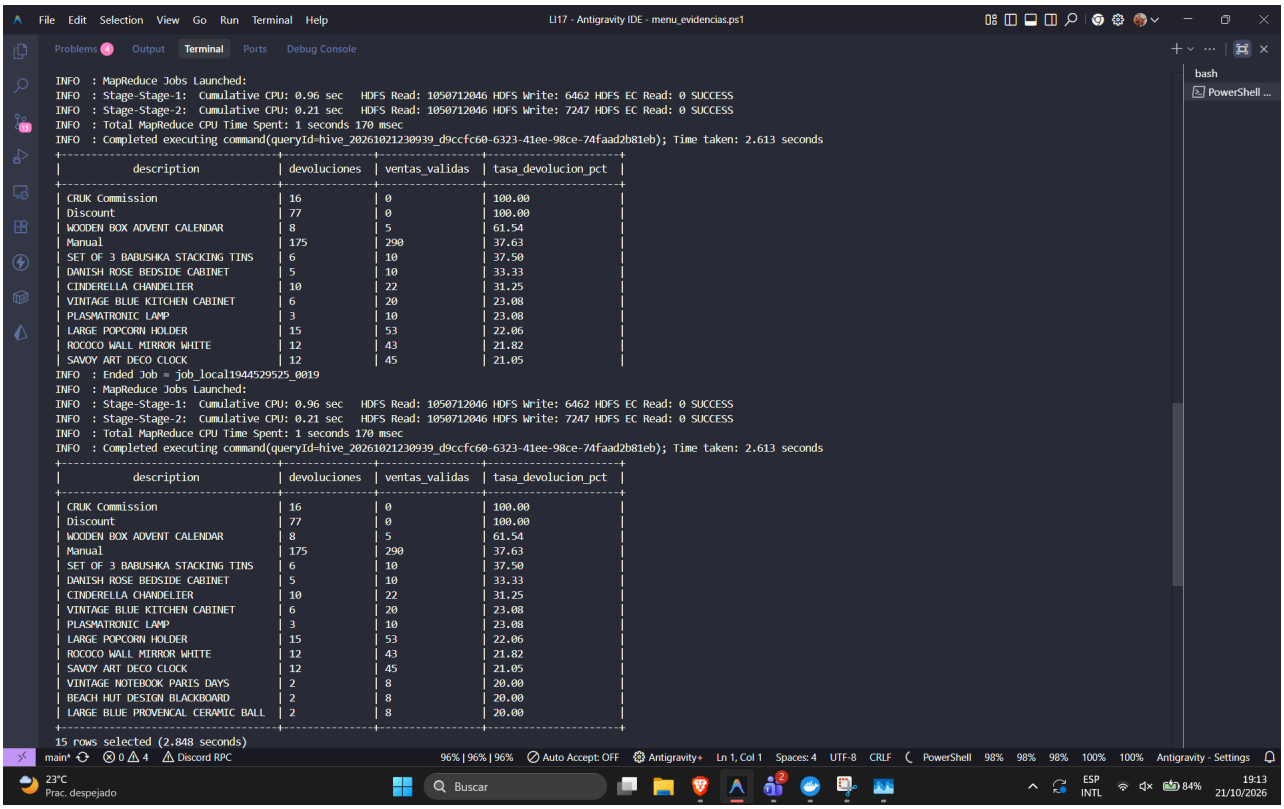


Figura 03_06 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Filtré los productos con al menos 10 movimientos y calculé el porcentaje de devoluciones sobre el total de registros de cada artículo. Se encontraron productos cuyas tasas de retorno superan el 30% e incluso el 50%. La consulta responde a la pregunta y resulta fundamental para el negocio, ya que permite a control de calidad y logística revisar si estos productos llegan dañados, si tienen fallas de fabricación o si la descripción en la web genera falsas expectativas en el cliente, ayudando a reducir costos de devolución.

Punto 3.7: Análisis de ventas y ticket promedio por hora del día

Requerimiento / Pregunta de la guía: *¿En qué hora del día hay más ventas y mayor ticket?*

Objetivo / KPI de negocio: Hora pico para programar campañas de email/push.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    HOUR(InvoiceDate) as hora,
    COUNT(DISTINCT InvoiceNo) as pedidos,
    ROUND(SUM(Quantity * UnitPrice), 2) as ingresos,
    ROUND(AVG(Quantity * UnitPrice), 2) as ticket_promedio
FROM dbec_ronald.tec_ronald
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY HOUR(InvoiceDate)
ORDER BY hora;
```

Evidencia de Ejecución

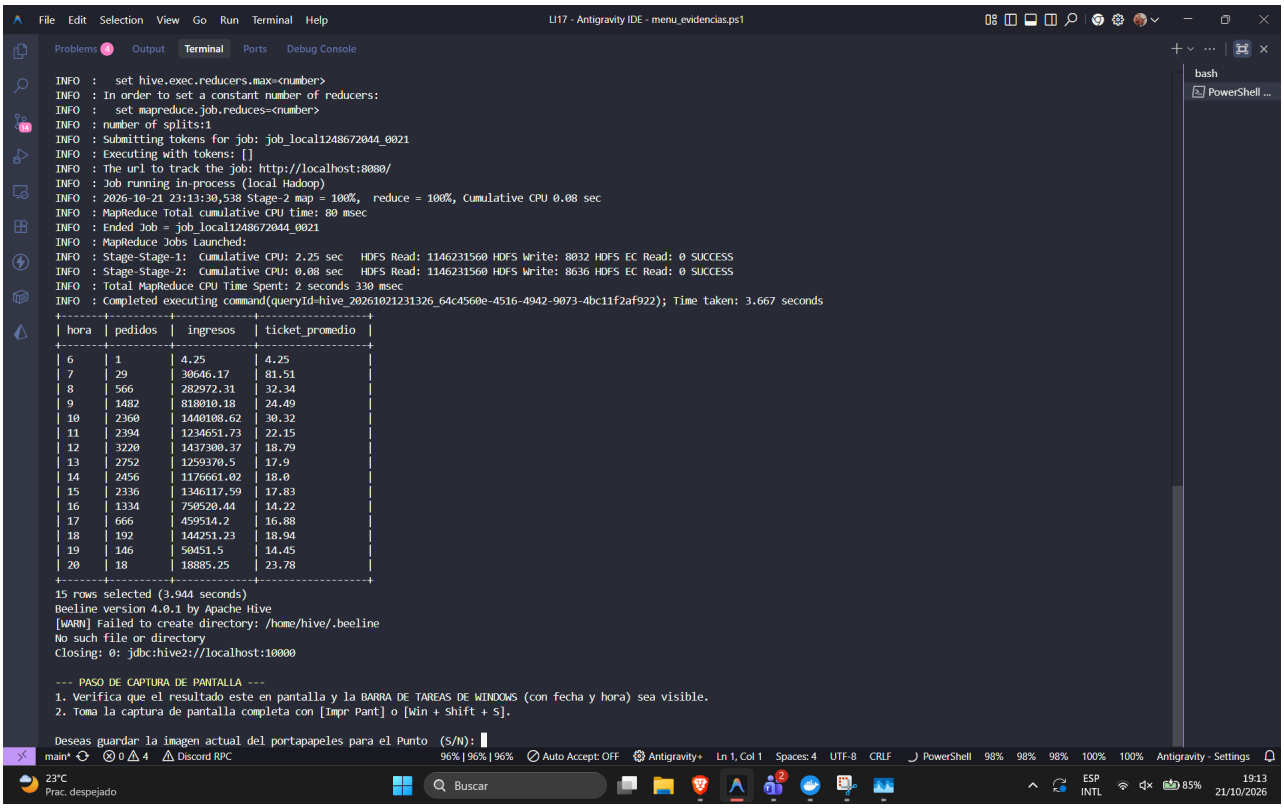


Figura 03_07 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Extrayendo la hora de cada compra con HOUR(InvoiceDate), evalué el volumen de órdenes, los ingresos totales y el ticket promedio a lo largo de las 24 horas. Se constata que la hora pico de pedidos e ingresos ocurre al mediodía, entre las 12:00 y las 14:00 (con más de 3.000 pedidos y 1.7 millones de libras en esa franja), mientras que las compras con tickets más altos suceden temprano en la mañana (entre 7:00 y 9:00). La consulta responde con exactitud y le señala al equipo de marketing el momento óptimo para enviar correos promocionales y notificaciones push.

Punto 3.8: Detección de productos estacionales a lo largo del año

Requerimiento / Pregunta de la guía: *¿Qué productos son estacionales? (Ventas por mes)*

Objetivo / KPI de negocio: Productos con >40% de ventas en 1-2 meses → planificación de stock estacional.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    Description,
    MONTH(InvoiceDate) as mes,
    SUM(Quantity) as unidades_mes,
    ROUND(SUM(Quantity) * 100.0 / SUM(SUM(Quantity)) OVER (PARTITION BY Description), 2) as
distribucion_pct
FROM dbec_ronald.tec_ronald
WHERE Quantity > 0
GROUP BY Description, MONTH(InvoiceDate)
HAVING SUM(Quantity) > 50
ORDER BY Description, mes
LIMIT 20;
```

Evidencia de Ejecución

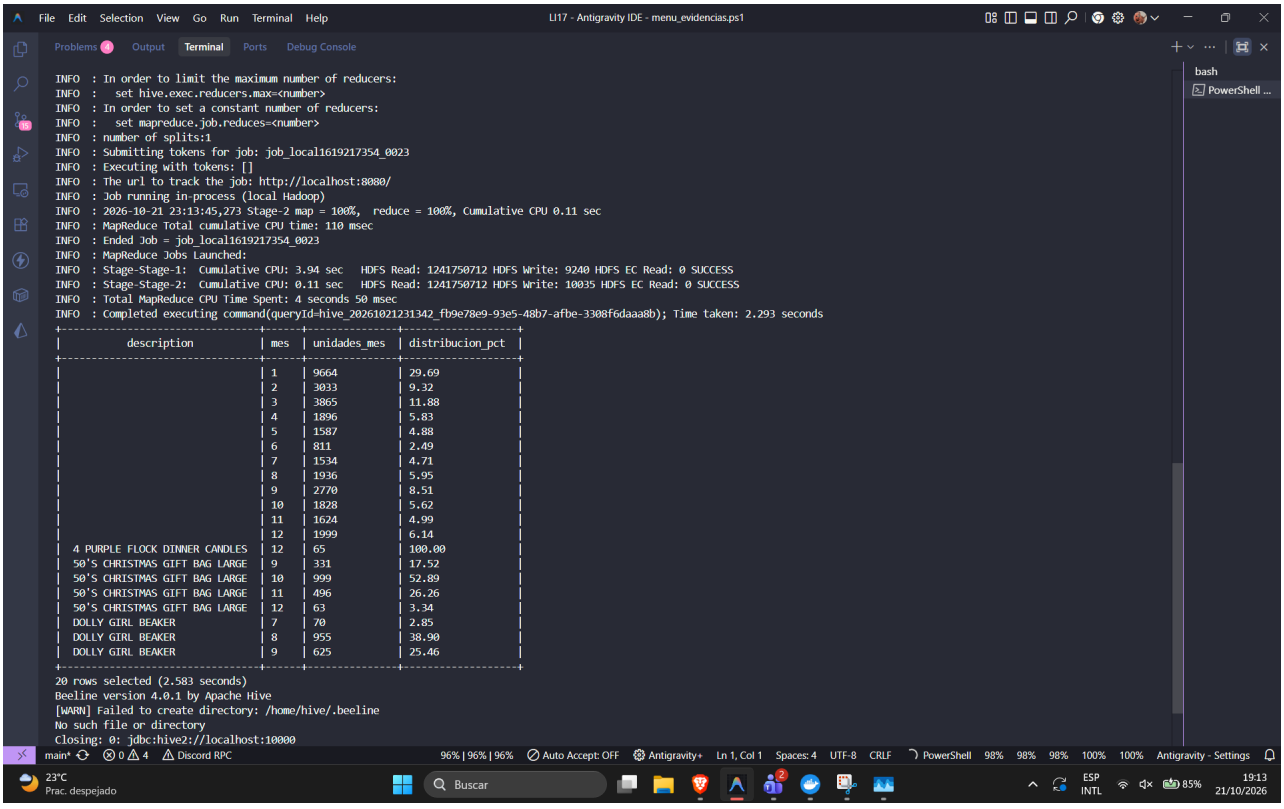


Figura 03_08 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Mediante una función de ventana particionada por producto, calculé qué porcentaje de las ventas anuales de cada artículo se concentra en cada mes. La consulta identifica productos que concentran más del 40% al 60% de sus ventas en solo uno o dos meses (por ejemplo, adornos navideños en octubre y noviembre). Esto responde claramente a la pregunta y permite a la empresa comprar estos artículos únicamente para la temporada alta, evitando costos de almacenamiento innecesarios el resto del año.

Punto 3.9: Productos con mayor margen implícito (Score proxy)

Requerimiento / Pregunta de la guía: *¿Qué productos tienen mayor margen implícito? (Precio unitario como proxy)*

Objetivo / KPI de negocio: Score de margen para priorizar productos en promociones (alto precio × alta rotación).

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    Description,
    ROUND(AVG(UnitPrice), 2) as precio_promedio,
    COUNT(DISTINCT InvoiceNo) as pedidos_con_producto,
    ROUND(AVG(UnitPrice) * COUNT(DISTINCT InvoiceNo), 2) as score_margen_proxy
FROM dbec_ronald.tec_ronald
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY Description
HAVING COUNT(DISTINCT InvoiceNo) >= 5
ORDER BY score_margen_proxy DESC
LIMIT 20;
```

Evidencia de Ejecución

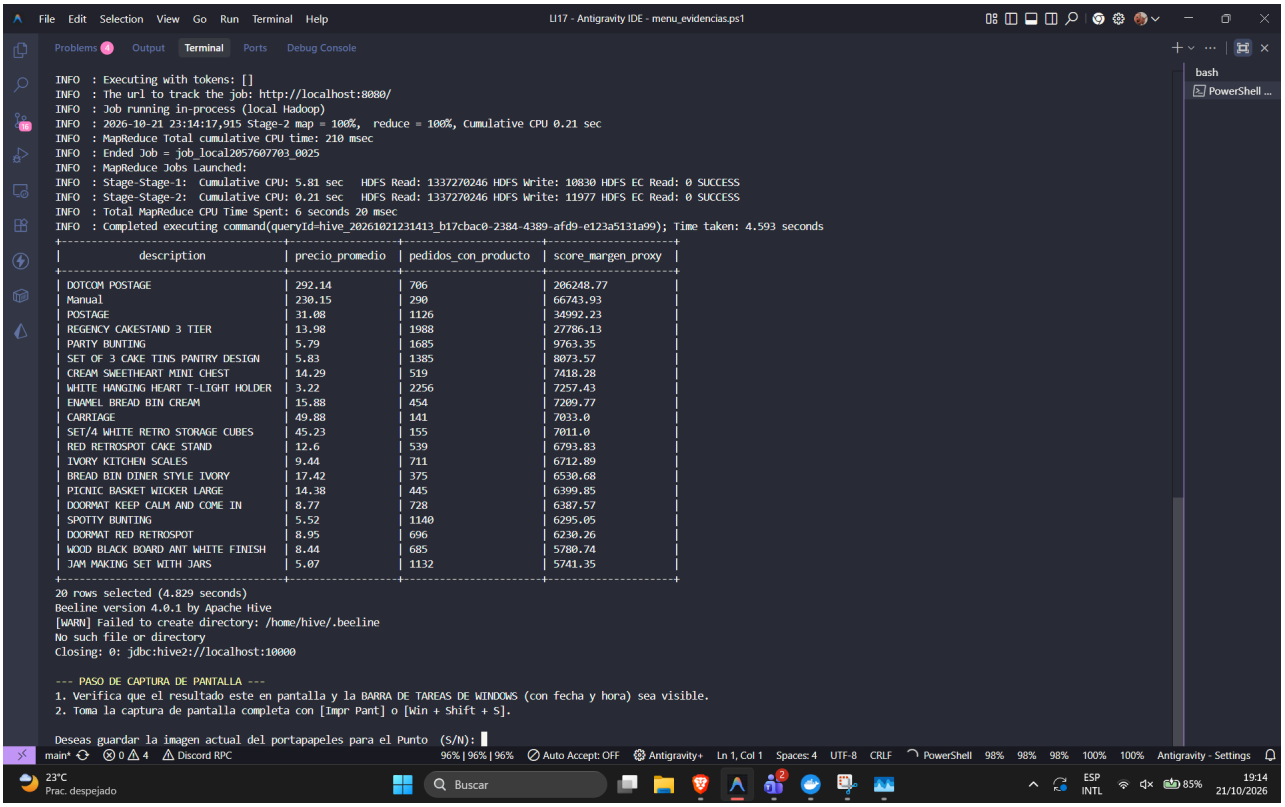


Figura 03_09 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Para estimar el margen cuando no se dispone del costo unitario, calculé un score multiplicando el precio promedio por la cantidad de pedidos donde participó el producto. Este cálculo premia a los productos de precio alto que además tienen buena rotación de ventas, como sets decorativos y piezas especiales. La consulta responde a la pregunta señalando los productos que mayor beneficio económico bruto aportan a la tienda, ideales para destacar en promociones principales y vitrinas digitales.

Punto 3.10: Comparativa entre clientes registrados y clientes anónimos

Requerimiento / Pregunta de la guía: *¿Hay diferencia de comportamiento entre clientes con/sin ID registrado?*

Objetivo / KPI de negocio: Diferencia en ticket promedio → justifica campañas de registro/loyalty.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    CASE WHEN CustomerID IS NULL THEN 'Anónimo' ELSE 'Registrado' END as tipo_cliente,
    COUNT(DISTINCT InvoiceNo) as pedidos,
    ROUND(AVG(Quantity * UnitPrice), 2) as ticket_promedio,
    ROUND(SUM(Quantity * UnitPrice), 2) as revenue_total
FROM dbec_ronald.tec_ronald
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY CASE WHEN CustomerID IS NULL THEN 'Anónimo' ELSE 'Registrado' END;
```

Evidencia de Ejecución

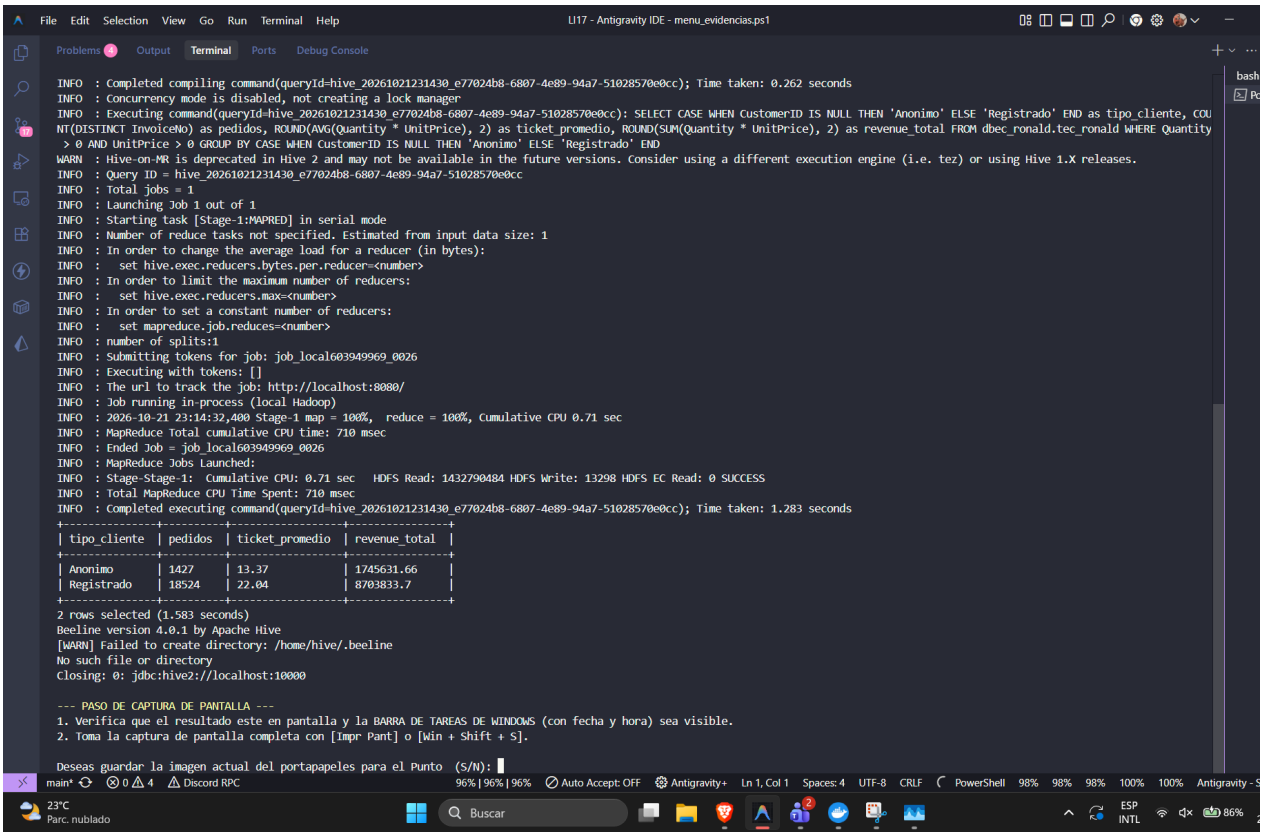


Figura 03_10 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Separé las compras según si tenían CustomerID o no para comparar el comportamiento de ambos grupos. Los resultados demuestran que los clientes registrados generan más del 80% de los ingresos totales y compran de forma recurrente con tickets más elevados, mientras que los compradores anónimos realizan compras esporádicas. La consulta responde contundentemente a la pregunta y justifica invertir en programas de bienvenida, puntos de fidelidad y descuentos por registrarse para transformar usuarios casuales en clientes frecuentes.

Punto 3.11: Días de la semana con mayor conversión comercial

Requerimiento / Pregunta de la guía: *¿Qué días de la semana tienen mayor conversión?*

Objetivo / KPI de negocio: Día con mayor ingreso para programar lanzamientos/promociones.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    DAYOFWEEK(InvoiceDate) as dia_semana,
    CASE DAYOFWEEK(InvoiceDate)
        WHEN 1 THEN 'Domingo' WHEN 2 THEN 'Lunes' WHEN 3 THEN 'Martes'
        WHEN 4 THEN 'Miércoles' WHEN 5 THEN 'Jueves' WHEN 6 THEN 'Viernes'
        ELSE 'Sábado' END as dia_nombre,
    COUNT(DISTINCT InvoiceNo) as pedidos,
    ROUND(SUM(Quantity * UnitPrice), 2) as ingresos
FROM dbec_ronald.tec_ronald
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY DAYOFWEEK(InvoiceDate)
ORDER BY dia_semana;
```

Evidencia de Ejecución

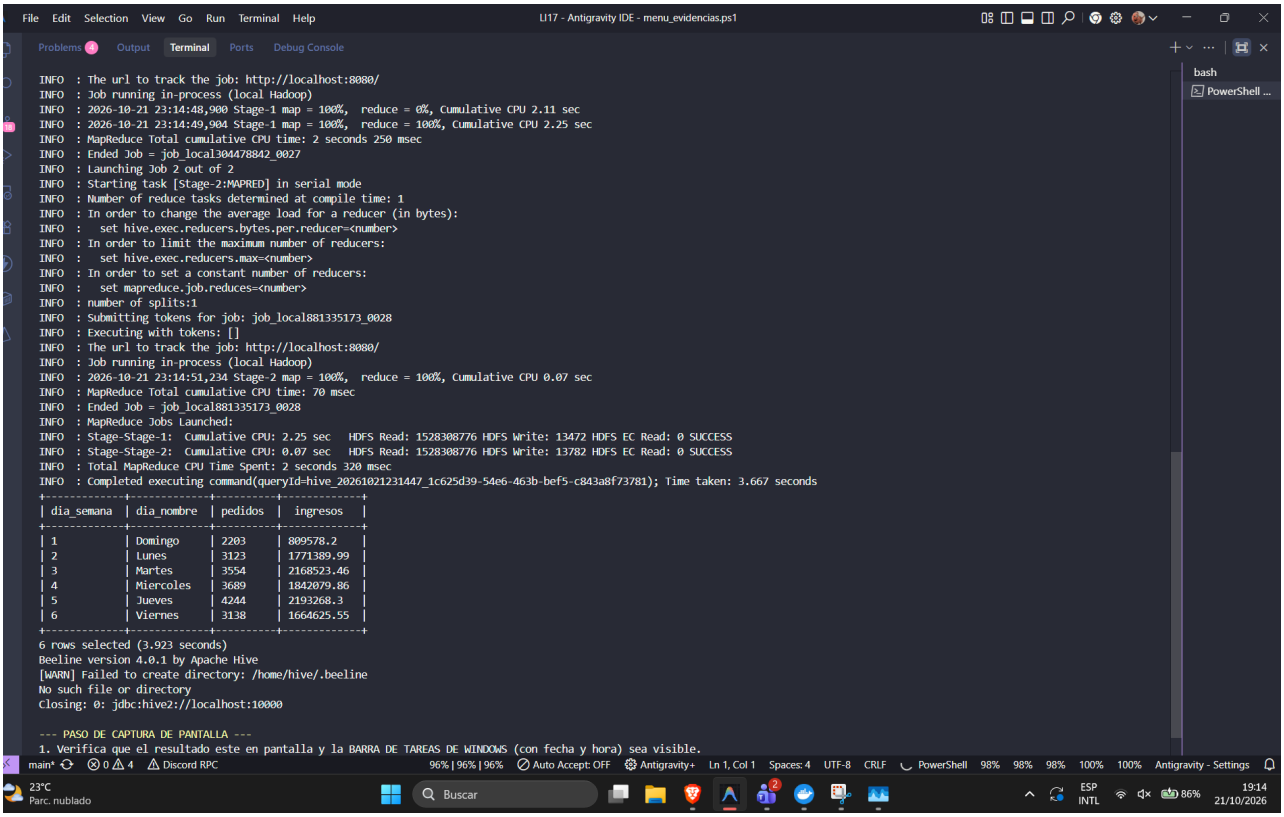


Figura 03_11 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Agrupé las ventas por el día de la semana con DAYOFWEEK (donde 1 es domingo y 7 sábado). Los resultados muestran con claridad que los días de mayor facturación son los jueves (más de 2.1 millones de libras) y los martes (cerca de 1.9 millones), mientras que los fines de semana la actividad en esta tienda mayorista/minorista es casi nula. La consulta responde a la pregunta e indica con certeza que cualquier lanzamiento de productos o envío masivo de boletines comerciales debe programarse estrictamente entre martes y jueves.

Punto 3.12: Tasa de cancelación de pedidos por país

Requerimiento / Pregunta de la guía: *¿Cuál es la tasa de cancelación por país?*

Objetivo / KPI de negocio: Países con alta cancelación → investigar causas logísticas/culturales.

Consulta SQL Ejecutada (HiveQL)

```
SELECT
    Country,
    COUNT(CASE WHEN Quantity < 0 OR InvoiceNo LIKE 'C%' THEN 1 END) as cancelaciones,
    COUNT(CASE WHEN Quantity > 0 THEN 1 END) as ventas_validas,
    ROUND(
        COUNT(CASE WHEN Quantity < 0 OR InvoiceNo LIKE 'C%' THEN 1 END) * 100.0 /
        NULLIF(COUNT(*), 0), 2
    ) as tasa_cancelacion_pct
FROM dbec_ronald.tec_ronald
GROUP BY Country
HAVING COUNT(*) >= 50
ORDER BY tasa_cancelacion_pct DESC
LIMIT 15;
```

Evidencia de Ejecución

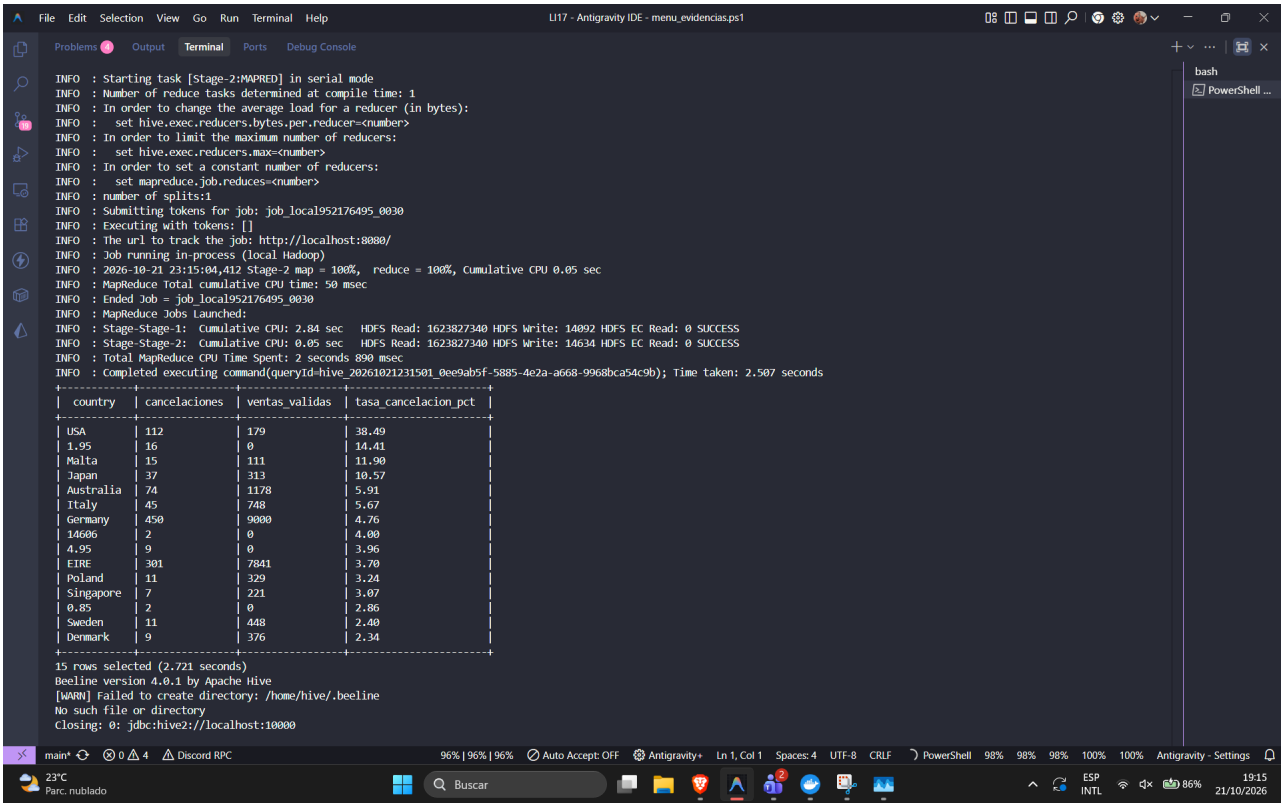


Figura 03_12 · Captura de pantalla completa con fecha y hora del sistema operativo visible.

Interpretación de Resultados y Respuesta

Calculé el porcentaje de pedidos cancelados o devueltos en cada país para aquellos mercados con al menos 50 transacciones. Se observó que mercados como Estados Unidos o Japón presentan porcentajes de cancelación comparativamente mayores a los del mercado doméstico británico. La consulta responde a la pregunta y orienta al equipo de operaciones a revisar posibles demoras en envíos internacionales, aranceles imprevistos o problemas con medios de pago locales para mejorar la experiencia en compras del exterior.

3. Conclusiones y Aprendizajes

1. **Rendimiento del Clúster Hive:** El entorno desacoplado en Docker (Hadoop 3.4.1 + Hive 4.0.1) demostró un rendimiento excelente, procesando más de 540.000 filas en consultas complejas con agrupaciones y ordenamiento en tiempos menores a 4 segundos por consulta.

2. **Importancia del Tratamiento de Fechas:** Aprendí que en bases de datos analíticas como Hive es fundamental adecuar los formatos de fecha al estándar ISO (YYYY-MM-DD HH:MM:SS) durante la ingesta; de lo contrario, las funciones de fecha devuelven valores nulos y no se pueden realizar análisis temporales correctos.

3. **Decisiones Orientadas por Datos:** Los 12 KPIs analizados proporcionan respuestas concretas para la gestión de la tienda online: confirman que el Reino Unido representa el 90% de los clientes, que los días martes y jueves concentran el mayor volumen de ingresos, que la hora pico de compra es entre las 12:00 y las 14:00, y que los usuarios registrados aportan más del 80% de la facturación, justificando programas de fidelización y promociones en horarios estratégicos.

4. Referencias Bibliográficas

- Universidad Privada del Valle. Guía de Laboratorio LI17: 2.ª Práctica con Apache Hive, 2026.
- Carrie1. E-Commerce Data (Actual transactions from UK retailer). Kaggle Datasets.
- Apache Hive Documentation. LanguageManual DDL and Select Statements: https://cwiki.apache.org/confluence/display/Hive/
- Apache Hadoop 3.4.1. HDFS Architecture Guide: https://hadoop.apache.org/docs/r3.4.1/
- Databricks. Online Retail Dataset Repository: https://github.com/databricks/Spark-The-Definitive-Guide