UNIVERSIDAD DEL VALLE

LI16 - Práctica con Apache Hive (1)

Para este laboratorio, usted debe contar con docker y docker-composer desde el sistema operativo Ubuntu de preferencia:

1. (Opcional): Tomar en cuenta qué contenedores existen en su equipo; preferentemente, **debe estar vacío** para facilidad de interpretación.

2. Deberá usar un ***repositorio diferente al de big data europe***, puede usar el que vio con su grupo.

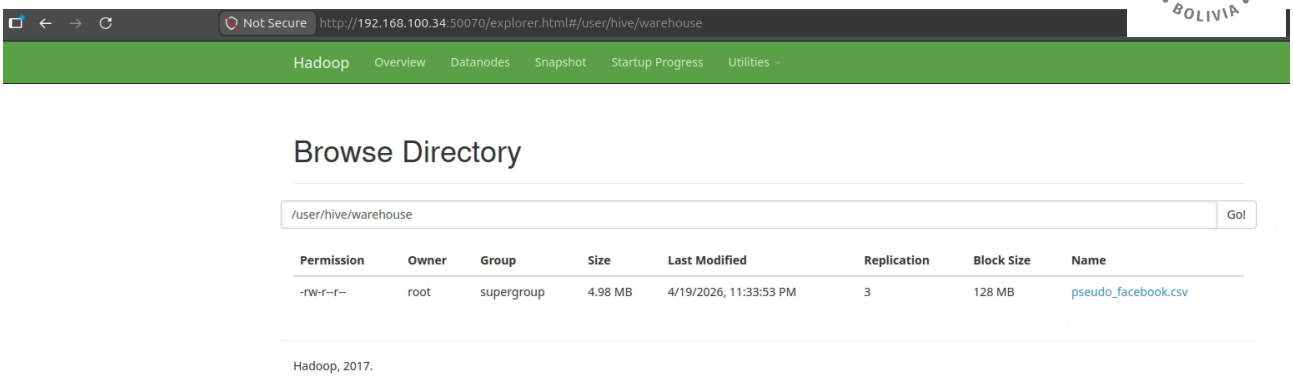
   Clonar el repositorio en una carpeta diferente que usted considere, con el comando: git clone <repositorio>
   https://github.com/big-data-europe/docker-hive.git

3. Debe ingresar a la carpeta que se descarga denominada “docker-hive” y ejecutar el comando: **docker-compose up -d,** segun la arquitectura de su repositorio
4. Listar los contenedores con el comando: docker ps
5. De la lista anterior, realice un análisis reflexivo y describa en un párrafo cada uno de los contenedores haciendo un poco de investigación:

Contenedor	Relación y comprensión con la exposición (un párrafo)
docker-hive_hive-server_1	

6. Acceder al shell del contenedor namenode con el comando: docker exec -it **docker-hive_namenode_1** /bin/bash
7. Una vez que haya ingresado **al shell del contenedor** **docker-hive_namenode_1**, realice las siguientes tareas:
   a. Listar el HDFS con el comando: hdfs dfs -ls /user/hive/warehouse/
      [Describa en un párrafo qué observa]

8. Acceda a la interfaz web del **docker-hive_namenode_1**, valide cuál es su IP del host y a qué puerto está vinculado entre el Docker y el host.
   a. Como recordatorio, si ve algo asi 0.0.0.0:**1234** -> **4321** **{Rojo es el puerto de cara al host, Verde es el puerto de cara al docker}.** Despliegue la interfaz web en el IP del host y puerto para el host.
9. En la interfaz web podrá encontrar una opción Utilities -> Browse the file system, revise qué archivos se encuentran en la ruta /user/hive/warehouse/



10. Descarga en la máquina host/anfitrión el siguiente dataset; debe tener claro dónde lo está descargando:
    https://www.kaggle.com/code/youssefabdelghfar/facebook-data-analysis/input
    Descomprimir y cambiar el nombre a **pseudo_facebook_tunombre.csv (tomar en cuenta que debe estar tu nombre).**
11. Quitar la primera línea o encabezado del archivo descargado para que no presente problema la carga de CSV a la tabla más adelante.
12. Copiar el archivo **pseudo_facebook_tunombre.csv** del host a la ruta /tmp/ en el contenedor namenode con el siguiente comando:
    docker cp **pseudo_facebook_tunombre.csv** **docker-hive_namenode_1**:/tmp/
13. Ingresar al shell de namenode y realizar las siguientes tareas:
    a. Ingresar a la carpeta donde se copiaron los archivos del host con el comando: cd /tmp/
    b. Subir al HDFS el archivo a analizar denominado **pseudo_facebook_tunombre.csv** con el comando: hdfs dfs -put **pseudo_facebook_tunombre.csv** /user/hive/warehouse/
    c. Listar con el comando: hdfs dfs -ls /user/hive/warehouse/
14. Acceder al shell de docker-hive_hive-server_1: docker exec -it **docker-hive_hive-server_1** /bin/bash
15. Acceder a hive desde el container **docker-hive_hive-server_1** con el comando: hive
    a. Crear una base de datos denominada **db_tunombre** con el comando:
    create database **db_tunombre;**
    b. Identifique qué columnas tiene su archivo **pseudo_facebook_tunombre.csv** y determine los tipos de datos que le corresponden:

Columna	Tipo de dato
userid	int (o bigint)
age	int
dob_day	int
…	

    c. Crear una tabla denominada **fb_tunombre** tomando en cuenta los tipos de datos definidos anteriormente, con el comando:
    CREATE TABLE db_pepe.fb_pepe(
    id int, age int, day int, year int, month int,
    gender string, tenure int, friends int, friends_init int,

likes int, likes_recd int, mlikes int, mlikes_rcd int,
wlikes int, wlikes_rcd int
)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ','
STORED AS TEXTFILE;

d. Revisa que el valor de location llegue hasta la tabla creada fb_tunombre con el comando: DESCRIBE FORMATTED db_tunombre.fb_tunombre;

e. Cargar los datos del CSV a la tabla creada con el comando: LOAD DATA INPATH '/user/hive/warehouse/**pseudo_facebook_tunombre.csv**' INTO TABLE db_tunombre.fb_tunombre;
f. Mostrar los primeros 10 registros con el comando: select * from fb_tunombre limit 10;

16. Responder un párrafo en sus palabras después de cada evidencia, a los siguientes requerimientos en base a sus conocimientos de SQL:

a. Determinar el número total de usuarios del dataset.
b. Determinar el número de usuarios de Facebook **por encima** de los 25 años.
c. Determinar si los usuarios masculinos o femeninos tienden a tener más amigos.
d. ¿Determinar cuántos 'me gusta' reciben los jóvenes (13-25 años) en Facebook en comparación con los usuarios mayores (mayores de 35 años)?
e. Encuentra el número de usuarios de Facebook para cada mes de cumpleaños.
f. ¿Los jóvenes (13-25 años) usan más el celular o la computadora para usar Facebook?
g. ¿Los adultos (mayores de 25 años) usan más el celular o la computadora para usar Facebook?

NOTA: Desarrollar un documento informe que presente una evidencia en imagen por cada punto requerido en el presente laboratorio; las condiciones de validez son:

- Debe apreciarse la hora de su sistema operativo.
- El contenido del documento debe ser mínimamente:
  - Portada que indique la materia, nombre del estudiante, número o código de práctica.
  - Debe mencionar el punto requerido (resaltado o pintado de amarillo) y la evidencia de respuesta que presenta al requerimiento; si considera necesario, puede incluir texto de aclaración.