UNIVERSIDAD DEL VALLE

LI17 - 2.ª Práctica con Apache Hive

Para este laboratorio, se asume que ya tiene Apache Hive corriendo:

1. Descargue el siguiente dataset:
   https://www.kaggle.com/datasets/carrie1/ecommerce-data

2. **Cada persona trabaja con un entorno diferente al de big data europe.**
   Acceder a Hive desde el contenedor **docker-hive_hive-server_1** con el comando: hive
   a. Crear una base de datos denominada **dbec_tunombre** con el comando:
      create database **dbec_tunombre;**
   b. Identifique qué columnas tiene su archivo **data_tunombre.csv** y determine los tipos de datos que le corresponden:

Columna	Tipo de dato
InvoiceNo	int
StockCode	string
Description	string
…	

   c. Crear una tabla denominada **tec_tunombre** tomando en cuenta los tipos de datos definidos anteriormente (revisa tu anterior práctica para guiarte).

```
CREATE TABLE grupoa.tablita(
id int, age int)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ','
STORED AS TEXTFILE;
```

   d. Revisa que el valor de location llegue hasta la tabla creada **tec_tunombre** con el comando: DESCRIBE FORMATTED **dbec_tunombre**.**tec_tunombre**;

   e. Cargar los datos del CSV a la tabla creada.
   f. Mostrar los primeros 10 registros

3. Los siguientes son preguntas que ya vienen con su respuesta y una descripción del KPI que se está obteniendo, en este punto particular deberá:
   a. **Comprenda la pregunta.**
   b. **Debe probar cada SQL sugerido.**

c. En un párrafo explicar lo que hace la consulta y si responde a l
requerida, además de responder a la pregunta.

Nivel básico

¿Cuál es el ingreso total generado por ventas válidas?

```
SELECT
    ROUND(SUM(Quantity * UnitPrice), 2) as ingreso_total
FROM ecommerce.retail
WHERE Quantity > 0
  AND UnitPrice > 0
  AND CustomerID IS NOT NULL;
```

KPI: Ingreso total validado para reporting financiero.

¿Cuáles son los 10 productos más vendidos por cantidad?

```
SELECT
    Description,
    SUM(Quantity) as unidades_vendidas,
    COUNT(DISTINCT InvoiceNo) as pedidos_con_producto
FROM ecommerce.retail
WHERE Quantity > 0
GROUP BY Description
ORDER BY unidades_vendidas DESC
LIMIT 10;
```

KPI: Top productos para priorizar stock y promoción.

¿Cuántos clientes únicos hay por país?

```
SELECT
    Country,
    COUNT(DISTINCT CustomerID) as clientes_unicos,
    ROUND(COUNT(DISTINCT CustomerID) * 100.0 /
        SUM(COUNT(DISTINCT CustomerID)) OVER (), 2) as porcentaje
FROM ecommerce.retail
WHERE CustomerID IS NOT NULL
GROUP BY Country
ORDER BY clientes_unicos DESC;
```

KPI: Distribución geográfica para focalizar expansión.

¿Cuál es el ticket promedio por orden?

```
SELECT
    ROUND(AVG(order_total), 2) as ticket_promedio,
    PERCENTILE_APPROX(order_total, 0.5) as mediana_ticket
FROM (
    SELECT
        InvoiceNo,
        SUM(Quantity * UnitPrice) as order_total
    FROM ecommerce.retail
    WHERE Quantity > 0 AND UnitPrice > 0
    GROUP BY InvoiceNo
) orders;
```

KPI: Ticket promedio vs. mediana para detectar sesgo por outliers.

¿Cómo evolucionan las ventas mes a mes?

```
SELECT
    YEAR(InvoiceDate) as anio,
```

```
    MONTH(InvoiceDate) as mes,
    COUNT(DISTINCT InvoiceNo) as pedidos,
    ROUND(SUM(Quantity * UnitPrice), 2) as ingresos
FROM ecommerce.retail
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY YEAR(InvoiceDate), MONTH(InvoiceDate)
ORDER BY anio, mes;
```

KPI: Tendencia mensual para planificación de inventario.

Nivel intermedio

¿Qué productos tienen mayor tasa de devolución/cancelación?

```
SELECT
    Description,
    COUNT(CASE WHEN Quantity < 0 OR InvoiceNo LIKE 'C%' THEN 1 END) as devoluciones,
    COUNT(CASE WHEN Quantity > 0 THEN 1 END) as ventas_validas,
    ROUND(
        COUNT(CASE WHEN Quantity < 0 OR InvoiceNo LIKE 'C%' THEN 1 END) * 100.0 /
        NULLIF(COUNT(*), 0), 2
    ) as tasa_devolucion_pct
FROM ecommerce.retail
WHERE CustomerID IS NOT NULL
GROUP BY Description
HAVING COUNT(*) >= 10
ORDER BY tasa_devolucion_pct DESC
LIMIT 15;
```

KPI: % devoluciones por producto para reducir desperdicio logístico.

¿En qué hora del día hay más ventas y mayor ticket?

```
SELECT
    HOUR(InvoiceDate) as hora,
    COUNT(DISTINCT InvoiceNo) as pedidos,
    ROUND(SUM(Quantity * UnitPrice), 2) as ingresos,
    ROUND(AVG(Quantity * UnitPrice), 2) as ticket_promedio
FROM ecommerce.retail
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY HOUR(InvoiceDate)
ORDER BY hora;
```

KPI: Hora pico para programar campañas de email/push.

¿Qué productos son estacionales? (Ventas por mes)

```
SELECT
    Description,
    MONTH(InvoiceDate) as mes,
    SUM(Quantity) as unidades_mes,
    ROUND(SUM(Quantity) * 100.0 / SUM(SUM(Quantity)) OVER (PARTITION BY Description),
2) as distribucion_pct
FROM ecommerce.retail
WHERE Quantity > 0
```

```
GROUP BY Description, MONTH(InvoiceDate)
HAVING SUM(Quantity) > 50
ORDER BY Description, mes;
```

KPI: Productos con >40% de ventas en 1-2 meses → planificación de stock estacional.

¿Qué productos tienen mayor margen implícito? (Precio unitario como proxy)

```
SELECT
    Description,
    ROUND(AVG(UnitPrice), 2) as precio_promedio,
    COUNT(DISTINCT InvoiceNo) as pedidos_con_producto,
    ROUND(AVG(UnitPrice) * COUNT(DISTINCT InvoiceNo), 2) as score_margen_proxy
FROM ecommerce.retail
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY Description
HAVING COUNT(DISTINCT InvoiceNo) >= 5
ORDER BY score_margen_proxy DESC
LIMIT 20;
```

KPI: Score de margen para priorizar productos en promociones (alto precio × alta rotación).

¿Hay diferencia de comportamiento entre clientes con/sin ID registrado?

```
SELECT
    CASE WHEN CustomerID IS NULL THEN 'Anónimo' ELSE 'Registrado' END as tipo_cliente,
    COUNT(DISTINCT InvoiceNo) as pedidos,
    ROUND(AVG(Quantity * UnitPrice), 2) as ticket_promedio,
    ROUND(SUM(Quantity * UnitPrice), 2) as revenue_total
FROM ecommerce.retail
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY CASE WHEN CustomerID IS NULL THEN 'Anónimo' ELSE 'Registrado' END;
```

KPI: Diferencia en ticket promedio → justifica campañas de registro/loyalty.

¿Qué días de la semana tienen mayor conversión?

```
SELECT
    DAYOFWEEK(InvoiceDate) as dia_semana,  -- 1=Domingo, 7=Sábado
    CASE DAYOFWEEK(InvoiceDate)
        WHEN 1 THEN 'Domingo' WHEN 2 THEN 'Lunes' WHEN 3 THEN 'Martes'
        WHEN 4 THEN 'Miércoles' WHEN 5 THEN 'Jueves' WHEN 6 THEN 'Viernes'
        ELSE 'Sábado' END as dia_nombre,
    COUNT(DISTINCT InvoiceNo) as pedidos,
    ROUND(SUM(Quantity * UnitPrice), 2) as ingresos
FROM ecommerce.retail
WHERE Quantity > 0 AND UnitPrice > 0
GROUP BY DAYOFWEEK(InvoiceDate)
ORDER BY dia_semana;
```

KPI: Día con mayor ingreso para programar lanzamientos/promociones.

¿Cuál es la tasa de cancelación por país?

```
SELECT
    Country,
    COUNT(CASE WHEN Quantity < 0 OR InvoiceNo LIKE 'C%' THEN 1 END) as cancelaciones,
    COUNT(CASE WHEN Quantity > 0 THEN 1 END) as ventas_validas,
    ROUND(
        COUNT(CASE WHEN Quantity < 0 OR InvoiceNo LIKE 'C%' THEN 1 END) * 100.0 /
```

```
        NULLIF(COUNT(*), 0), 2
    ) as tasa_cancelacion_pct
FROM ecommerce.retail
GROUP BY Country
HAVING COUNT(*) >= 50
ORDER BY tasa_cancelacion_pct DESC;
```

KPI: Países con alta cancelación → investigar causas logísticas/culturales.

NOTA: Desarrollar un documento informe que presente una evidencia en imagen por cada punto requerido en el presente laboratorio; las condiciones de validez son:

- Debe apreciarse la hora de su sistema operativo.
- El contenido del documento debe ser mínimamente:
    - Portada que indique la materia, nombre del estudiante, número o código de práctica.
    - Debe mencionar el punto requerido (resaltado o pintado de amarillo) y la evidencia de respuesta que presenta al requerimiento; si considera necesario, puede incluir texto de aclaración.